

Nöron Ağları ile Duygu Analizi

Şaban Murat Altun, Sefa Tunca, Hüseyin Kırıcı, Enes Akbaş
210202026, 220202101, 210202008, 210202010

Bilgisayar Mühendisliği, Kocaeli Üniversitesi
Nöron Ağlarına Giriş Dersi Dönem Projesi

Abstract

Bu çalışma, sosyal medya platformlarından (özellikle Twitter) toplanan kullanıcı yorumlarını analiz ederek, metinlerin duygu durumlarını (pozitif, negatif, nötr veya alakasız) sınıflandırmayı amaçlayan bir duygu analizi projesidir. Yorumlar, yapay zeka tabanlı bir sınıflandırma modeline girdi olarak kullanılmadan önce kapsamlı bir doğal dil işleme (NLP) ön işleme sürecinden geçirilmektedir. Elde edilen önışlenmiş veriler, markaların müşteri geri bildirimlerini daha etkili analiz edebilmelerini sağlamak ve stratejik karar alma süreçlerini desteklemek amacıyla yapay sinir ağı modelleriyle işlenmiştir. Bu doğrultuda, sınıflandırma görevinde Multi-Layer Perceptron (MLP) ve Recurrent Neural Network (RNN) mimarileri kullanılmıştır.

Keywords: Duygu Analizi; Doğal Dil İşleme; Metin Sınıflandırma; Multi-Layer Perceptron; Recurrent Neural Network

1 Giriş

Günümüzde sosyal medya, bireylerin duygu ve düşüncelerini ifade ettikleri en yaygın platformlardan biri haline gelmiştir. Özellikle Twitter gibi mecralarda paylaşılan kısa metinler, kullanıcıların ürünler, hizmetler veya olaylar hakkındaki görüşlerini doğrudan yansıttığı için, bu verilerden anlam çıkarmak kurumlar açısından stratejik bir önem taşımaktadır. Bu bağlamda, çalışmamız; sosyal medya yorumlarının duygu durumlarını (pozitif, negatif, nötr veya alakasız) sınıflandırmak amacıyla gerçekleştirilmiş bir duygu analizi uygulamasıdır.

Yorumlar, yapay zeka tabanlı sınıflandırma modellerine girdi olarak kullanılmadan önce, detaylı bir doğal dil işleme (NLP) ön işleme sürecinden geçirilmiştir. Bu süreçte; URL ve kullanıcı adlarının kaldırılması, kısaltmaların açılması, metinlerin küçük harfe dönüştürülmesi, sayılar ve noktalama işaretlerinin temizlenmesi ile anlam taşımayan (negatif anlamlılar hariç) stopword'lerin ayıklanması gibi adımlar yer almaktadır.

Ön işleme sonrasında metin verileri sayısal vektörlere dönüştürülerek analiz için uygun hale getirilmiştir. Bu dönüştürme aşamasında TF-IDF, Bag of Words (BoW), Word2Vec, GloVe ve FastText gibi farklı kelime gömme (word embedding) teknikleri kullanılmıştır. Her yöntem, kelimeler arası anlamsal ilişkileri farklı biçimlerde modelleyerek sınıflandırma modellerinin başarısını artırmayı hedeflemiştir.

Son aşamada, elde edilen bu sayısal temsiller kullanılarak metinlerin duygu etiketlerini tahmin eden modeller oluşturulmuştur. Bu çalışmada hem zamansal bağımlılıkları öğrenmeye uygun olan Recurrent Neural Network (RNN) mimarisi hem de katmanlı yapısıyla güçlü öğrenme

yeteneğine sahip Multi-Layer Perceptron (MLP) mimarisi kullanılmıştır. Eğitim ve test aşamalarında model performansları doğruluk, precision, recall ve F1 skoru gibi değerlendirme metrikleri ile analiz edilmiştir.

2 Literatür Taraması

Bu çalışmada ele alınan konuya yönelik daha önce yapılmış araştırmalar incelenerek, alandaki mevcut yöntemler, kullanılan teknikler ve elde edilen sonuçlar değerlendirilmektedir.

Batbaatar ve arkadaşları (Batbaatar vd., 2019) [1], metinlerden duygu tanıma görevini gerçekleştirmek üzere, hem anlamsal (semantik) hem de duygusal ilişkileri birlikte ele alan yeni bir sinir ağı mimarisi olan SENN (Semantic-Emotion Neural Network) modelini önermişlerdir. Bu model, kısa metinlerdeki duyguları yüksek doğrulukla tanımayı hedeflemektedir. Önerilen mimari, biri semantik bilgi, diğeri ise duygusal bilgi odaklı iki alt ağdan oluşmaktadır. Semantik alt ağda, sözcüklerin bağlamsal ilişkilerini öğrenmek için çift yönlü uzun-kısa süreli bellek (BiLSTM) yapısı kullanılmıştır. Duygusal alt ağda ise, sözcüklerin duygusal ilişkilerini öğrenmek için evrişimli sinir ağı (CNN) kullanılmıştır. Bu iki alt ağ, Word2Vec, GloVe ve FastText gibi önceden eğitilmiş sözcük gömme (embedding) modellerinden elde edilen vektörleri kullanarak beslenmiştir. Ayrıca, duygu odaklı embedding'ler de CNN ağına giriş olarak verilmiştir. Modelin son katmanında, BiLSTM ve CNN ağlarının çıktıları birleştirilmiş ve softmax sınıflandırıcı ile duygu tahmini yapılmıştır.

Chen ve arkadaşları (2011)[2], blog yazılarındaki duyguları sınıflandırmak amacıyla sinir ağı tabanlı bir yöntem geliştirmiştir. Çalışmada, duygu yönelimi indeksleri (SO-A, SO-PMI(AND), SO-PMI(NEAR), SO-LSA) sinir ağına giriş olarak verilmiştir. Blog yorumlarından elde edilen terim-doküman matrisleri ile birlikte, aday özellikler olarak sıfat ve zarflar POS etiketleme yöntemiyle seçilmiştir. Veri eğitim ve test setlerine ayrılarak geri yayılım sinir ağı (BPN) eğitilmiştir. En iyi performansı elde etmek için ağ yapısı ve parametreleri deneme-yanılma ile optimize edilmiştir. Yöntem, klasik duygu yönelimi indekslerine ve diğer sinir ağı yaklaşımlarına kıyasla daha yüksek doğruluk sunmuştur.

Despotovic ve Tanikic (2017) [3], mikrobloğlardan duygu analizini gerçekleştirmek amacıyla ileri beslemeli yapay sinir ağı (ANN) tabanlı bir yöntem önermiştir. Bu yöntemi, Multinomial Naive Bayes, Destek Vektör Makineleri (SVM) ve Maksimum Entropi gibi makine öğrenimi algoritmalarıyla karşılaştırmışlardır. Çalışmada, Stanford Twitter Sentiment (dengeli ve zayıf etiketli) ile SemEval-2014 Task 9 (dengesiz ve elle etiketlenmiş) veri kümeleri kullanılmıştır. Özellik çıkarımı olarak kelime sayımları, bigramlar ve önışleme teknikleri (stop-word kaldırma, kök bulma, hiperlink ve kullanıcı adı temizleme vb.) uygulanmıştır. Eğitim aşamasında SCG algoritması kullanılarak, geleneksel yöntemlere göre daha hızlı ve verimli öğrenme sağlanmıştır. Elde edilen sonuçlar, ANN yaklaşımının duygu analizinde mevcut yöntemlerle karşılaştırıldığında üstün veya en azından karşılaştırılabilir performans sunduğunu göstermektedir.

Kim ve arkadaşları (2022) [4], küfürlü ifadelerin duygu analizine etkisini yapay sinir ağları (ANN) ile incelemiştir. RNN yapılarında görülen gradyan kaybı (vanishing gradient) problemini aşmak için LSTM kullanılmıştır. Çalışmada biri küfürlü ifadeleri içeren, diğeri ise bu ifadeleri temizleyen iki ayrı model geliştirilmiştir. Her iki model aynı veri seti ve aynı hiperparametrelerle eğitilerek karşılaştırılmıştır. Veri kümesi olarak "Naver Sentiment Movie Corpus v1.0" kullanılmıştır. Sonuçlar, küfürlü içeriklerin sınıflandırma doğruluğunu önemli ölçüde etkilediğini göstermiştir.

Sharma ve arkadaşları (2016) [5], sosyal medya platformlarından elde edilen verilerle duygu analizini geliştirmek amacıyla olasılıksal sinir ağı (PNN) tabanlı bir yöntem önermiştir. Twitter API aracılığıyla "NSG" etiketiyle toplanan 300 tweet, ön işleme ve vektörleştirme adımlarından geçirilerek sınıflandırmaya uygun hale getirilmiştir. Araştırmada iki farklı model geliştirilmiştir: tüm sınıflar için ortak bir yumuşatma parametresi kullanan PNNS ve her sınıf için ayrı yumuşatma parametresi kullanan PNNC. PNN yapısı; giriş, desen, toplama ve çıktı katmanlarından oluşmakta

olup, Gaussian fonksiyonu ile örnekler arasındaki benzerlik ölçülmektedir. PNNC modelinin sınıf başına optimize edilen yumuşatma parametresi sayesinde PNNs modeline kıyasla daha yüksek doğruluk sağladığı gözlemlenmiştir. Bu çalışma, duygu analizinde PNN'nin öğrenme hızı ve yüksek doğruluk potansiyeli sunduğunu göstermektedir.

Hasan, Rundensteiner ve Agu (2019) çalışmalarında [6], bir sosyal medya platformu olan Twitter üzerinden elde edilen metin verileri aracılığıyla otomatik duygu tespiti yapılmıştır. Bu amaçla Naive Bayes, Maximum Entropy ve Support Vector Machines (SVM) gibi denetimli sınıflandırma algoritmaları kullanılmış; paylaşımların kısa yapısı, bağlam eksikliği, dilin öznel doğası gibi çeşitli zorluklar vurgulanmıştır. Ayrıca, duygu dengesizliği ve kültürel farklılıklar gibi etmenlerin sınıflandırma başarısını olumsuz etkilediği ifade edilmiştir. Tüm bu sınırlamalara rağmen çalışma, sosyal medya verileri üzerinden duygu çıkarımı konusunda temel oluşturmakta ve daha hassas modeller için bir çerçeve sunmaktadır.

Binali, Wu ve Potdar (2010) çalışmalarında [7], duygu tespitine yönelik üç ana yaklaşım olan sözlük tabanlı, makine öğrenimi tabanlı ve derin öğrenme tabanlı yöntemler ele alınmıştır. Sözlük tabanlı yöntemler uygulama kolaylığı sağlarken, bağlamdan bağımsız oldukları için düşük doğruluk göstermektedir. Makine öğrenimi teknikleri ise özellik mühendisliğine ve etiketli veri setlerine bağlıdır. Derin öğrenme yaklaşımları, bağlamı daha iyi yakalayabilen yapılar sunarken, yüksek işlem gücü ve veri gereksinimi gibi sınırlamalara sahiptir. Ek olarak, çalışma duygu tespiti zorlukları olarak ironi, dil çeşitliliği, kültürel farklar ve öznellik gibi konulara dikkat çekmiştir.

Tao (2004) çalışmasında [8], geleneksel duygu analiz yöntemlerinin kelime düzeyinde işlem yaparak bağlamı yeterince değerlendirmediklerini vurgulamıştır. Bu eksikliği gidermek amacıyla, kelimelerin yalnızca bireysel anlamlarına değil, aynı zamanda içinde bulundukları cümle ve paragraf bağlamına göre analiz edilmesi gerektiği ifade edilmiştir. Çalışmada önerilen sistem, bağlamsal ipuçlarını değerlendirerek daha yüksek doğrulukla duygu sınıflandırması gerçekleştirmiştir. Bu sayede duygu analizinde anlam derinliği ve bağlam ilişkisi ön plana çıkarılmıştır.

Acheampong, Wenyu ve Nunoo-Mensah (2020) çalışmalarında [9], metin tabanlı duygu tespitinin mevcut durumu, kullanılan yöntemler ve karşılaşılan zorluklar sistematik biçimde sunulmuştur. Özellikle SemEval, ISEAR ve EmoBank gibi yaygın veri setlerinin kullanımı ve değerlendirme metrikleri (Accuracy, Precision, Recall, F1-Score) üzerine kapsamlı bilgi verilmiştir. Derin öğrenme tekniklerinin geleneksel yöntemlere göre daha başarılı olduğu vurgulanmış, kısa metinlerden bağlam çıkarımı, çok dilli analiz, emojilerin yorumu ve sarkazm tespiti gibi güncel problemler ele alınmıştır. Ayrıca, sağlık ve suç önleme gibi uygulamalarda duygu analizinin genişletilmesi gerektiği ifade edilmiştir.

Agrawal ve An (2012) çalışmalarında [10], duygu tespiti için etiketli veri ya da elle hazırlanmış sözlükler kullanmaksızın denetimsiz bir öğrenme yöntemi önermektedir. Çalışma, kelimeler için hesaplanan duygu vektörlerini hem anlamsal (semantic) hem de yapısal (sentaktik) ilişkilerle değerlendirerek bağlamsal analiz yapmaktadır. Bu bağlam temelli ve esnek yapı sayesinde, önceki yöntemlere kıyasla daha doğru sonuçlar elde edildiği gösterilmiştir. Özellikle sınırlı duygu kümesine bağlı kalmadan, daha geniş ve doğal bir duygu sınıflandırması sağlanmıştır.

Jianqiang ve arkadaşları çalışmalarında [11], Twitter verileri üzerinde duygu analizi yapmak amacıyla geliştirilen bir yöntem sunulmaktadır. Geleneksel yaklaşımların aksine yalnızca açıkça görülen sözcüksel ve sözdizimsel özelliklere (duygu kelimeleri, emojiler, ünlem işaretleri vb.) odaklanmak yerine, bu çalışma tweet'lerdeki kelimeler arasındaki gizli bağlamsal ve eşgörünüm ilişkilerini yakalayan kelime gömme (word embedding) yöntemini kullanır. Bu gömüler, n-gram

özellikleri ve kelime duygu kutupluluğu skorları ile birleştirilerek tweet'ler için zengin bir özellik seti oluşturulur. Bu özellikler, duygu sınıflandırma etiketlerini tahmin etmek üzere derin bir evrişimli sinir ağına (CNN) entegre edilmiştir. Beş farklı Twitter veri kümesi üzerinde yapılan deneyler, önerilen modelin temel n-gram tabanlı modele göre doğruluk ve F1 skorlarında üstün performans gösterdiğini ortaya koymuştur.

Arkhipenko ve arkadaşları çalışmalarında [12], Rusça tweet'ler üzerinde gerçekleştirilen duygu analizi çalışmasını sunmaktadır. Çalışmada bankalar ve telekomünikasyon şirketleri hakkında yazılmış mesajlardaki duyguların (olumlu, olumsuz, nötr) sınıflandırılması hedeflenmiştir. Yazarlar, üç farklı denetimli makine öğrenmesi yaklaşımını karşılaştırmıştır: GRU (Gated Recurrent Unit) tabanlı tekrarlayan sinir ağı, evrişimsel sinir ağı (CNN) ve domain uyarlaması içeren bir SVM sınıflayıcı. Tüm yöntemlerde, sosyal ağlardan toplanan milyonlarca gönderiyle eğitilen word2vec kelime vektörleri özellik olarak kullanılmıştır. Modeller, organizatörlerin sağladığı etiketli eğitim verileri ile eğitilmiştir. Değerlendirme sonuçlarına göre, GRU tabanlı model hem bankacılık hem de telekom alanlarında en yüksek makro ortalama F1 skorunu elde etmiştir ve bankalar için mikro ortalama F1 skorunda da en iyi sonucu vermiştir. Araştırma, sinir ağı temelli modellerin duygu analizinde üstün performans gösterdiğini ortaya koymaktadır [12].

Wang ve arkadaşları çalışmalarında [13], kısa metinlerde duygu analizi yapmak için birleştirilmiş bir CNN ve RNN mimarisi sunmaktadır. CNN, metin içindeki yerel özellikleri çıkarırken; RNN, bu özellikleri kullanarak uzun mesafeli bağımlılıkları öğrenir. Böylece kısa metinlerin sınırlı bağlamsal bilgisini dengelemek hedeflenmiştir. Sistem, önceden eğitilmiş kelime gömme (word embedding) temsillerini CNN'e girdi olarak alır ve çeşitli pencere boyutları ile farklı filtreler kullanarak özellik haritaları oluşturur. Bu özellikler RNN'e aktarılır, burada öğrenilen tümcecik temsilleri bir tam bağlantılı katman ve softmax sınıflandırıcısıyla duygu etiketine dönüştürülür. Yöntem, üç farklı veri kümesinde (MR, SST1, SST2) test edilmiş ve sırasıyla %82.28, %51.50 ve %89.95 doğruluk ile önceki çalışmaları geride bırakmıştır. Çalışmanın temel katkısı, CNN'in yerel yapıları ve RNN'in ardışık bağımlılıkları birlikte işlemesiyle kısa metinlerdeki duygu analizini daha etkili biçimde gerçekleştirmesidir.

Nistor ve arkadaşları çalışmalarında [14], Twitter verileri üzerinde duygu analizi yapmak için tekrar eden sinir ağlarına (RNN) dayalı bir sistem önermektedir. 1.5 milyon tweet'ten oluşan büyük bir veri kümesiyle eğitilen model, farklı mimari tasarımlar (LSTM, GRU, dikkat mekanizması vb.) denenerek optimize edilmiştir. En başarılı sonuç, iki katmanlı ve 64 birimli GRU mimarisıyla elde edilmiştir (%80.74 doğruluk). Karakter düzeyinde giriş ve one-hot vektörleme gibi yöntemlerle tweet'lerdeki bilgi kaybı azaltılmıştır. Geliştirilen model, SynergyCrowds platformunda kripto para tweet'lerinin duygusunu ölçmek için kullanılmaktadır.

Cai ve arkadaşları çalışmalarında [15], sosyal medya paylaşımlarındaki metin ve görsel içeriğin bir arada kullanıldığı duygu analizi için yeni bir yöntem öneriyor. Özellikle, metinler ve görsellerin ayrı ayrı analiz edilmesinin yerine, her ikisinin birlikte değerlendirilmesinin daha doğru bir duygu analizi sunduğu vurgulanıyor. Yöntem, metinsel ve görsel özellikleri öğrenmek için iki ayrı konvolüsyonel sinir ağı (CNN) mimarisi kullanıyor ve bu özellikler, metin ve görsel arasındaki ilişkileri keşfetmek için bir başka CNN mimarisıyla birleştiriliyor. Gerçek dünyadaki iki veri seti üzerinde yapılan deneyler, önerilen yöntemin metin ve görsellerin birleşik bilgisini kullanarak etkili bir duygu analizi sağladığını gösteriyor.

Ankit ve arkadaşları çalışmalarında [16], yelp restoran inceleme veri seti , film inceleme veri seti ve amazon ürün inceleme veri seti gibi veri setleri üzerinde ANN mimarilerinde metinlerdeki olumsuzluk ifadelerinin (negation) doğru bir şekilde duygu analizinde ele alınmasını analiz edip incelemiştir. Bu kapsamda uygulanan başlıca adımlar şunlardır: URL ve kullanıcı adları yer tu-

tucularla değiştirilerek anlam karmaşası engellenir. Kısaltmalar, bilgi kaybını önlemek amacıyla açılır (“don’t” → “do not”). Sayılar, duygu içermediğinden metinden çıkarılır. Metin küçük harfe çevrilir, böylece sözcükler standardize edilir. Tokenizasyon ile metin sözcük düzeyine ayrılır. Stopword’ler kaldırılır ancak “not”, “no”, “never” gibi önemli olumsuzluk kelimeleri korunur. Stemming, sözcükleri kök haline indirger (“playing” → “play”). Olumsuzluk işleme, “not good” ifadesinin “bad” gibi bir zıt anlamlıya dönüştürülmesiyle gerçekleştirilir. Bu işlemde WordNet sözlüğü kullanılarak anlam bütünlüğü korunur.

Mikolov ve arkadaşlarının bu çalışması[17], kelime temsillerinin verimli öğrenimi için CBOW ve Skip-gram modellerini sunarak doğal dil işlemede önemlidönüm noktası oluşturmıştır. Sonuç olarak, bu modeller büyük ölçekli veri kümelerinde etkili şekilde çalışabilmekte, kelimeler arasındaki karmaşık semantik ve sözdizimsel ilişkileri başarıyla yakalayabilmektedir. Çalışma, geleneksel yöntemlere kıyasla hem hesaplama verimliliği hem de performans açısından önemli bir ntajlar sağladığını kanıtlamış ve word2vec’in temelini oluşturarak sonraki dil modeli çalışmalarına yol gösterici olmuştur.

Glenn ve arkadaşlarının bu çalışması [18],Endonezya Twitter verileri üzerinde duygu sınıflandırmasıdır. Geleneksel yöntemlerin aksine sadece açık kaynaklı veri ve modeller kullanarak RNN tabanlı yaklaşımları denemişler. Özellikle FastText ile desteklenen BiLSTM modelinin yüksek doğruluk verdiğini gözlemlemişler. Bu model, kapalı kaynaklı özelliklerle eğitilen modeller kadar başarılı sonuçlar üretmiş. Sonuç olarak, dil modeli ve veri açık kaynak olsa bile güçlü sonuçlar alınabileceğini göstermişler.

Sunagar ve arkadaşlarının bu çalışması [19], metin sınıflandırması için geleneksel makine öğrenmesi yöntemlerinden sinir ağlarına geçişi vurgulayarak, geleneksel RNN modellerini farklı katmanlarla (LSTM ve GRU) birleştirerek doğruluğu test etmeyi amaçlamaktadır. Araştırma, RNN+LSTM+GRU hibrit modelini RCNN+LSTM ve RNN+GRU modelleriyle karşılaştırmış, eğitim için GloVe veri setini kullanmış ve F1 skoru, kesinlik ve geri çağırma metrikleriyle modellerin performansını değerlendirmiştir. Hibrit RNN modelinin üç LSTM ve iki GRU katmanından oluştuğu, RCNN modelinin dört evrişim ve dört LSTM katmanı içerdiği, RNN modelinin ise dört GRU katmanı barındırdığı belirtilmiştir. Sonuçlar, RNN-GRU modelinin RCNN ve RNN-LSTM-GRU modellerinden daha iyi performans gösterdiğini, ancak uzun dönem bağımlılıklar için RNN-LSTM-GRU’nun tercih edildiğini ortaya koymuştur. Genel olarak, model seçimi zaman, veri seti boyutu ve uzun dönem bağımlılıkların yönetimi gibi değişkenler arasında bir denge gerektirmektedir.

Srinivasarao ve arkadaşlarının bu çalışması [20],gelen kutusu mesajlarındaki (SMS ve e-posta) spam ve ham ayrımını daha iyi yapmak için hibrit bir derin öğrenme yaklaşımı geliştirdik. İlk olarak, mesajları Kernel Extreme Learning Machine (KELM) sınıflandırıcısıyla spam ve ham olarak ayırdık. Ardından, bu sınıflandırılmış mesajlar üzerinde duygu analizi yaparak sınıflandırma doğruluğunu artırmak amacıyla bulanık tabanlı Tekrarlayan Sinir Ağı tabanlı Harris Hawk Optimizasyonu (FRNN-HHO) adımı verdiğimiz yeni bir model oluşturduk. Modelimizin performansını SMS, e-posta ve spam-assassin gibi farklı veri setlerinde test ettik ve yüksek AUC değerleri elde ettik. Bu sonuçlar, geliştirdiğimiz FRNN-HHO modelinin spam tespiti ve duygu analizinde oldukça etkili olduğunu gösteriyor.

3 Yöntem

Bu bölümde, sosyal medya verilerinin duygu durumlarına göre sınıflandırılması amacıyla uygulanan yöntemsel adımlar ayrıntılı olarak açıklanmıştır. Veri toplama sürecinden başlayarak, metinlerin doğal dil işleme teknikleriyle ön işlenmesi, sayısal vektör temsillerine dönüştürülmesi

ve farklı modellerin eğitilmesine kadar izlenen tüm süreçler sistematik biçimde sunulmuştur.

3.1 Veri Toplama

Twitter Sentiment Analysis veri kümesi, sosyal medya üzerindeki tweet'lerin belirli bir varlık (örneğin bir marka veya ürün) hakkında ifade ettiği duyguyu analiz etmek için hazırlanmıştır. Her bir tweet ilgili olduğu varlık, metin içeriği ve bu içeriğin pozitif, negatif, nötr veya alakasız olarak etiketlenmiş duygu durumu ile birlikte sunulmuştur. Eğitim ve doğrulama amaçlı iki ayrı dosya halinde sağlanan veri seti, duygu analizi projeleri için güçlü bir temel sunduğu için tercih edilmiştir. Veri kümesi, metin madenciliği, doğal dil işleme ve makine öğrenmesi tekniklerinin uygulanabileceği gerçek dünya verileri içerdiğinden, model geliştirme ve değerlendirme süreçleri için oldukça uygundur. Özellikle markaların müşteri algısını analiz etme ve strateji belirleme çalışmalarında kullanılabilir.

3.2 Metin Ön İşleme

3.2.1 URL'ler ve Kullanıcı Adlarını Tespit Edip Değiştirme

Bu işlemle, sosyal medya gibi platformlardan alınan metinlerde sıkça karşılaşılan bağlantılar (URL'ler) ve kullanıcı adları (@işaretili isimler) tespit edilip, bunların yerine sabit ifadeler yerleştiriliyor. Örneğin bir tweet'te geçen bir internet adresi "URL" kelimesiyle, bir kullanıcı adı da "AT-USER" ifadesiyle değiştiriliyor. Böylece model, bu tür detaylarla uğraşmak yerine metindeki esas anlamı öğrenmeye odaklanabiliyor. Bu sayede eğitim sürecinde daha anlamlı ve genel kalıpları yakalamayı hedefledik.

3.2.2 Kısaltmaların Açılması

Bu adım, metinlerdeki kısaltmaların (örneğin "don't" → "do not" veya "can't" → "can not") açılmasını sağlar. Bunun için **contractions** kütüphanesi kullanılır ve metinlerdeki kısaltmalar otomatik olarak doğru uzun formlarıyla değiştirilir. Bu işlem, özellikle olumsuzlukları doğru şekilde algılayabilmek için önemlidir çünkü kısaltmalar modelin doğru analiz yapmasını engelleyebilir. Böylece, metindeki anlam kaybı önlenir ve metin daha anlaşılır hale gelir.

3.2.3 Küçük Harfe Dönüştürme

Bu adımda metinler üzerinde küçük harfe dönüştürme işlemi yapılmıştır. Bu adım, "Good" ve "good" gibi aynı kelimenin farklı halleri arasında fark yaratılmasını engeller. Bu sayede, modelin hem büyük hem de küçük harfli kelimeleri aynı şekilde değerlendirmesi sağlanır. Böylece, metindeki anlam kaybı veya karışıklık önlenir. Küçük harfe dönüştürme, metinlerin daha tutarlı ve standart bir formatta analiz edilmesini sağlar.

3.2.4 Sayıların Kaldırılması

Metinlerden sayıları kaldırma işlemi yaptık. Bu adım, genellikle metinlerde duygu içeriği taşımayan sayıları çıkartarak, modelin daha anlamlı veriler üzerinde odaklanmasını sağlar. Sayılar, metnin duygu analizine katkı sağlamadığı için bu bilgileri temizledik. Böylece, sadece metnin anlamlı kısımlarına odaklanılmasına imkan tanıdık. Bu işlem, metnin daha temiz ve analiz edilebilir olmasını sağladı.

3.2.5 Noktalama İşaretlerinin Kaldırılması

Bu adımda noktalama işaretleri metinlerden kaldırılmıştır. Bu adım, metnin daha düzenli hale gelmesini sağlar çünkü genellikle duygu analizinde noktalama işaretleri anlam taşımayabilir.

Noktalama işaretlerinin çıkarılması, metnin sadece kelimelere dayalı analiz edilmesine olanak tanır. Bu işlem, modelin anlamlı bilgiye odaklanmasına yardımcı olarak daha doğru sonuçlar elde edilmesini sağlar.

3.2.6 Stopwords'lerin Kaldırması

Stopwords listesindeki olumsuzluk kelimelerini (negations) çıkararak metinlerde gereksiz kelimeleri temizledik. Bu işlem, duygu analizi ve metin madenciliği gibi uygulamalarda daha anlamlı sonuçlar elde edilmesini sağlamak için yapılmıştır. Stopwords genellikle metnin anlamını taşımayan yaygın kelimelerdir, ancak olumsuzluk kelimeleri anlamı değiştirebilir, bu yüzden onları koruduk. Metinleri kelime bazında temizlerken, stopwords listesindeki kelimeleri metinlerden çıkardık, böylece modelin sadece anlamlı kelimelerle çalışmasına olanak tanıdık.

3.2.7 Tokenizasyon

Metin üzerinde tokenizasyon işlemi gerçekleştirdik, yani metni kelimelere veya sembollere ayırdık. Bu işlem, metnin dil modeli için daha anlamlı hale gelmesini sağlar. Kısaltmalar açıldıktan sonra tokenizasyonu uyguladık, çünkü kısaltmaların doğru şekilde açılması, tokenizasyonun ardından daha düzgün sonuçlar verir. NLTK kütüphanesindeki word-tokenize fonksiyonunu kullanarak metinleri kelime bazında parçalara ayırdık. Bu sayede, her bir kelime üzerinde işlem yaparak daha hassas analizler yapabilmeyi sağladık.

3.2.8 Lemmatization

Metinlerdeki kelimeleri kök haline indirmek için lemmatization işlemi gerçekleştirdik. Bu işlem, kelimeleri anlamlı bir şekilde köklerine indirger, örneğin "playing" ve "played" kelimelerini "play" olarak dönüştürür. NLTK kütüphanesindeki **WordNetLemmatizer** ve **pos-tag** fonksiyonlarını kullanarak her kelimenin doğru türünü (fil, isim, sıfat, vs.) belirleyip, uygun şekilde kök haline indirdik. Bu sayede, modelin kelimelerin anlamlarını daha iyi kavrayabilmesini sağladık. Hem eğitim hem de doğrulama veri setlerinde bu işlemi uygulayarak, metinlerin doğru bir şekilde lemmatize edilmesini sağladık.

3.3 Metin Verilerini Sayısal Verilere (Vektörlere) Dönüştürme

Doğal dil işleme (NLP) uygulamalarında, metinlerin doğrudan matematiksel işlemlerde kullanılması mümkün olmadığından, bu metinlerin sayısal ifadelere dönüştürülmesi gerekmektedir. Bu dönüşüm, kelimelerin veya belgelerin belirli yöntemlerle vektör temsillerine (gömme/embedding) çevrilmesiyle gerçekleştirilir. Bu çalışmada, farklı gömme teknikleri kullanılarak metinler sayısal forma getirilmiş ve ardından sınıflandırma modellerine girdi olarak verilmiştir. Aşağıda, bu projede kullanılan dört temel yöntem açıklanmıştır: TF-IDF, Bag of Words, Word2Vec ve FastText.

3.3.1 TF-IDF (Term Frequency - Inverse Document Frequency)

TF-IDF, bir kelimenin belirli bir belge içerisindeki önem derecesini belirlemek amacıyla kullanılan istatistiksel bir yöntemdir. "Term Frequency" (TF), kelimenin belge içindeki sıklığını hesaplar, "Inverse Document Frequency" (IDF), bu kelimenin tüm belgeler arasında ne kadar nadir olduğunu gösterir. Bu iki değerin çarpımı, sık kullanılan ancak anlamsız kelimeleri baskılayarak anlamlı kelimeleri öne çıkarır. TF-IDF, özellikle metin sınıflandırma gibi denetimli öğrenme görevlerinde sıkça tercih edilir. Bu çalışmada, **scikit-learn** kütüphanesi kullanılarak TF-IDF vektörleştirme işlemi gerçekleştirilmiştir.

3.3.2 Bag of Words (BoW)

Bag of Words yöntemi, bir metni temsil etmek için kelime frekanslarını kullanır. Bu yöntem, kelime sırasını dikkate almadan her kelimenin metin içerisindeki tekrar sayısını bir vektör olarak ifade eder. BoW yaklaşımı basit ve hızlıdır ancak bağlamsal anlamı yansıtmakta yetersiz kalabilir. Bu projede BoW yöntemi, metinlerin temel özelliklerini hızlıca çıkarmak amacıyla kullanılmıştır. Kelime sıklık matrisleri oluşturulmuş ve bu matrisler sınıflandırma modellerine giriş olarak verilmiştir.

3.3.3 Word2Vec

Word2Vec, kelimeleri çok boyutlu sürekli vektörler halinde ifade eden ve kelimeler arası anlamsal benzerlikleri modelleyen gömme yöntemidir. Bu model, benzer bağlamlarda geçen kelimelerin benzer vektör temsillere sahip olmasını sağlar. Word2Vec, genellikle iki model mimarisi ile uygulanır: CBOW (Continuous Bag of Words) ve Skip-Gram. Bu çalışmada, **gensim** kütüphanesi kullanılarak önceden eğitilmiş Word2Vec vektörleri ile metinler vektörleştirilmiş ve derin öğrenme modellerine beslenmiştir.

3.3.4 FastText

FastText, Word2Vec'in bir uzantısı olarak geliştirilen ve kelimeleri alt parçalara (subword) ayırarak temsil eden bir gömme modelidir. Bu sayede, nadiren görülen ya da yazım hatası içeren kelimeler için bile anlamlı vektörler oluşturulabilir. Özellikle morfolojik olarak zengin dillerde daha başarılı sonuçlar verir. Bu projede, FastText'in sunduğu alt-kelime yapısının avantajlarından faydalanılarak daha genel ve bağlamsal vektör temsilleri elde edilmiştir. Model, Facebook tarafından geliştirilen önceden eğitilmiş FastText vektörleriyle uygulanmıştır.

3.3.5 Glove

GloVe, kelimelerin küresel ortak görünme istatistiklerinden yararlanarak kelime vektörleri üreten bir gömme yöntemidir. Word2Vec gibi yerel bağlam bilgisi yerine, kelime çiftlerinin tüm korpus genelindeki birlikte görülme frekanslarını modelleyerek anlamsal ilişkileri yakalar. Bu sayede, kelimeler arasındaki lineer ilişkiler (örneğin “kraliçe - kadın + erkek = kral” gibi) daha etkin biçimde temsil edilir. GloVe, büyük metin kütüphanelerinde etkili ve ölçeklenebilir sonuçlar sunar. Bu çalışmada, önceden eğitilmiş GloVe vektörleri kullanılarak metinler anlamlı ve yoğun temsil vektörlerine dönüştürülmüş, ardından sınıflandırma modellerine beslenmiştir.

3.4 Model Eğitimi

Bu bölümde, ön işleme ve vektörleştirme adımlarından geçirilen veriler kullanılarak gerçekleştirilen modellerin eğitim süreci ayrıntılı şekilde açıklanmıştır.

3.4.1 Multi-Layer Perceptron (MLP)

Metin sınıflandırma problemi için oluşturduğumuz modelde sınıflandırıcı olarak MLPClassifier (Multilayer Perceptron Classifier) kullanılmıştır. MLP, yapay sinir ağlarının temel biçimlerinden biridir ve bir giriş katmanı, bir veya daha fazla gizli katman ve bir çıkış katmanından oluşur. Bu yapıdaki her katman, bir önceki katmandan gelen sinyalleri ağırlıklandırarak işler ve bir aktivasyon fonksiyonu aracılığıyla çıktılar üretir. MLP'ler denetimli öğrenme kapsamında eğitilir ve geri yayılım (backpropagation) algoritması kullanılarak hata oranlarını minimize eder. Bu çok katmanlı yapı sayesinde MLP, doğrusal olmayan karar sınırlarını öğrenebilir ve karmaşık sınıflandırma problemlerinde etkin bir şekilde kullanılabilir [10].

Modelin performansını maksimuma çıkarmak amacıyla hiperparametre optimizasyonu yaptık. İlk olarak, geniş bir parametre uzayını hızlı şekilde taramak üzere RandomizedSearchCV yöntemini kullandık. Bu yöntem, daha düşük maliyetle daha geniş parametre uzaylarını keşfetmeyi sağlar [6]. Daha sonra elde ettiğimiz en iyi parametrelerin etrafında hassas ayar yapmak için HalvingGridSearchCV yöntemini kullandık. Bu yöntem sayesinde, her iterasyonda daha düşük performans gösteren parametre kombinasyonları kademeli olarak çıkarıldı ve böylece ideal parametre setine yaklaşıldı [6].

Özellik çıkarımı sürecinde Bag of Words yaklaşımı kullanılmış ve bu kapsamda CountVectorizer bileşeni tercih edilmiştir. Özellikle n-gram aralığı, algoritma tarafından metin analizi için en verimli sonuçları verdiği gözlemlendiğinden (1,2) olarak belirlenmiştir [7]. Ayrıca, çok yaygın ve çok nadir kelimeleri filtrelemek üzere max-df ve min-df parametreleri sırasıyla 0.98 ve 1 olarak ayarlanmıştır. Bu sayede modelin daha genelleyici ve stabil performans göstermesi sağlanmıştır [9]. Bu tür bağlamsal (context-based) çıkarımlar, metnin genel anlamına duyarlılık gösteren sistemler geliştirilmesinde de oldukça kritiktir [8].

Uygulanan hiperparametre optimizasyonu sonucunda, MLPClassifier için en uygun parametreler gizli katman boyutu (64,), düzenleme parametresi (alfa) $3.89e-7$ ve öğrenme oranı 0.00096 olarak belirlenmiştir. Bu ayarlamalar, modelin eğitim sürecinde daha hızlı ve kararlı bir şekilde yakınsamaya ulaşmasını sağlamış ve sınıflandırma başarısını önemli ölçüde artırmıştır. Optimizasyon öncesinde 0.89 olan accuracy skoru, optimizasyon sonrasında 0.92'ye yükselmiştir.

3.4.2 Recurrent Neural Network (RNN)

Recurrent Neural Network (RNN), ardışık verilerle çalışmak üzere tasarlanmış bir yapay sinir ağı mimarisidir. Özellikle doğal dil işleme (NLP) problemlerinde cümle içerisindeki kelimeler arasındaki bağımlılıkları modellemek için yaygın olarak kullanılmaktadır. RNN, önceki adımlardan gelen bilgileri hafızasında tutarak her bir zaman adımında bu bilgileri güncelleyebilmekte ve böylece metin gibi sıralı verilerdeki bağlamsal ilişkileri öğrenebilmektedir.

Bu çalışmada, sıralı metin verilerini daha iyi modelleyebilmek amacıyla Recurrent Neural Network (RNN) tabanlı iki farklı derin öğrenme mimarisi kullanılmıştır. İlk yaklaşımda, temel bir RNN yapısı olan SimpleRNN katmanını kullanarak bir model inşa edilmiştir. Ön işleme adımlarından geçirilmiş metin verileri uygun şekilde vektörleştirilmiş ve sabit uzunluktaki giriş vektörleri olarak modele verilmiştir. Modelin giriş katmanında veriler yeniden şekillendirilmiş ve ardından sıralı şekilde işlenmiştir. SimpleRNN katmanının ardından bir Dense katman, bir Dropout katmanı ve çok sınıflı sınıflandırma için softmax aktivasyonlu çıktı katmanı eklenmiştir. Bu yapı, metinlerin zaman içindeki sırasal yapısını temel düzeyde öğrenmeyi amaçlamaktadır. İkinci modelde ise daha güçlü bir mimari olan Bidirectional LSTM kullanılmıştır. Bu yapı, metin verilerini hem ileri hem de geri yönde okuyarak bağlamsal bilgiyi iki yönlü olarak işlemektedir. Böylece cümle içindeki her bir kelimenin yalnızca öncesi değil, aynı zamanda sonrasındaki kelimelerle olan ilişkisi de öğrenilebilmiştir. Modelin ilk katmanında çift yönlü bir LSTM katmanı yer almakta, ardından sırasıyla bir Dense katman, bir Dropout katmanı ve softmax ile çıktı katmanı gelmektedir. LSTM hücreleri, klasik RNN'lere kıyasla daha uzun bağımlılıkları öğrenme konusunda daha başarılıdır ve unutma/kaydetme mekanizmalarıyla bilgi kaybını azaltır.

Her iki model de Keras kütüphanesi kullanılarak **Sequential API** ile tanımlanmıştır ve sparse_categorical_crossentropy kayıp fonksiyonu ile eğitilmiştir. Model doğruluğu (accuracy) metriği üzerinden izlenmiş ve farklı mimarilerin duygu sınıflandırma görevindeki performansları karşılaştırılmıştır.

Eğitim sürecinde modellerin aşırı öğrenmesini (overfitting) önlemek ve gereksiz yere uzun süren eğitim döngülerini engellemek amacıyla Early Stopping yöntemi uygulanmıştır. Bu yöntemde, doğrulama (validation) kaybı üç ardışık epoch boyunca iyileşme göstermediğinde eğitim otomatik olarak durdurulmuştur (patience = 3). Böylece modelin genel performansını artırmak ve eğitim süresini optimize etmek hedeflenmiştir.

Table 2: Dosyalara Göre Etiket Dağılımları

Dosyalar	Pozitif	Negatif	Nötr	Alakasız (Irrelevant)
Train	20832	22542	18318	12990
Validation	277	266	285	172

Bu iki farklı RNN yaklaşımı sayesinde, hem temel hem de gelişmiş sıralı modelleme yeteneklerine sahip yapılar değerlendirilmiş; metinlerin içerdiği duygusal bağlamın daha doğru analiz edilmesi hedeflenmiştir.

4 Veri Kümesi Özellikleri

Twitter Duygu Analizi Veri Kümesi, metin tabanlı duygu analizine yönelik hazırlanmış bir veri kümesidir. Bu veri kümesinde her bir örnek; bir mesaj (tweet) ve bu mesaja konu olan belirli bir varlıktan (kuruluş, kişi, marka vb.) oluşmaktadır. Görevin amacı, mesajın söz konusu varlıkla ilgili taşıdığı duyguyu doğru şekilde sınıflandırmaktır.

Veri kümesindeki duygu etiketleri üç ana sınıfa ayrılmıştır:

Pozitif: Mesajın varlık hakkında olumlu bir görüş bildirdiği durumlar.

Negatif: Mesajın varlık hakkında olumsuz bir görüş içerdiği durumlar.

Nötr: Mesajın varlıkla ilgili tarafsız, bilgi verici veya yorumsuz bir ifade taşıdığı durumlar.

Ek olarak, varlıkla doğrudan ilişkili olmayan veya alakasız mesajlarla ilgili olan Irrelevant durumu vardır.

Veri seti iki dosyadan twitter_training.csv ve twitter_validation.csv oluşmaktadır. İçerdiği sütunlar Tweet ID ,entity,sentiment,Tweet contentdir. Burada Tweet content-sentiment ilişkisini ortaya koyulmaya çalışılmıştır.

Tweet ID	Entity	Sentiment	Tweet İçeriği
8312	Amazon	Neutral	“BBC News - Amazon boss Jeff Bezos rejects claims company acted like a 'drug dealer'.”
4371	Microsoft	Negative	“@Microsoft Why do I pay for WORD when it functions so poorly on my Chromebook?”
4433	CS-GO	Negative	“CSGO matchmaking is so full of closet hacking, it's a truly awful game.”
998	Facebook	Irrelevant (Neutral sayılmış)	“I mentioned on Facebook that I was struggling for motivation to go for a run the other day, which has been translated by Tom's great auntie as 'Hayley can't get out of bed' and told to his grandma, who now thinks I'm a lazy, terrible person.”

Table 1: Veri kümesinden seçilmiş örnek tweet kayıtları.

Training ve Validation dosyalarına göre dağılımlar aşağıdaki gibidir.

5 Sonuç

5.1 Multi-Layer Perceptron (MLP)

Bu çalışmada, metin sınıflandırma görevinde temel Bag of Words (BoW) modeli ile hiperparametre optimizasyonu uygulanmış bir modelin performansları karşılaştırılmıştır. Elde edilen sonuçlar, hiperparametre optimizasyonunun model başarımı üzerinde önemli bir iyileştirme sağladığını ortaya koymaktadır.

BoW modelinde genel doğruluk oranı %89 olarak gerçekleşmişken, hiperparametre optimizasyonu yapılan modelde bu oran %92'ye yükselmiştir. Ayrıca tüm sınıflar için hem precision, hem recall, hem de f1-score değerlerinde gözle görülür artışlar elde edilmiştir.

Makro ve ağırlıklı ortalama değerler incelendiğinde de benzer bir iyileşme görülmektedir; makro f1-score değeri %88'den %92'ye çıkarak modelin genel dengesini artırmıştır. Bu da modelin tüm sınıflarda daha tutarlı ve dengeli tahminler yaptığını göstermektedir.

Sonuç olarak, hiperparametre optimizasyonunun sadece doğruluk oranını artırmakla kalmayıp aynı zamanda modelin sınıflar arası performans dengesini de güçlendirdiği görülmektedir. Bu bulgular, metin sınıflandırma modellerinin performansını maksimize etmek için hiperparametre ayarlamalarının ne kadar kritik bir rol oynadığını açıkça ortaya koymaktadır.

Table 3: BoW ve hiperparametre optimizasyonlu modelin sınıf bazlı ve genel performans karşılaştırması.

Metrik / Sınıf	BoW Modeli	Optimize Model	Fark
Irrelevant	0.87	0.92	+0.05
Negative	0.90	0.93	+0.03
Neutral	0.87	0.92	+0.05
Positive	0.89	0.91	+0.02
Makro F1-Score	0.88	0.92	+0.04
Accuracy	0.89	0.92	+0.03

5.2 Recurrent Neural Network (RNN)

RNN tabanlı modeller, sıralı veriler üzerindeki güçlü öğrenme kapasiteleri sayesinde metinlerdeki bağlamsal ilişkileri yakalamada oldukça etkilidir. Bu çalışmada, hem temel bir RNN modeli hem de çift yönlü (Bidirectional) LSTM mimarisi kullanılarak duygu sınıflandırma görevine yönelik derin öğrenme çözümleri uygulanmıştır. Aşağıdaki tabloda, her bir modelin performansına ait karşılaştırmalı değerlendirmelere yer verilmiştir.

MLP'de uygulanan Bag of Words ve TF-IDF kelime sırasını ve bağlamı yok saydığı için, sabit boyutlu ve bağlamsız temsiller olduğundan RNN'de kullanmak için uygun değildir. Word2Vec, GloVe ve FastText SimpleRNN üzerine uygulandığında iyi performans elde edilemediğinden çift yönlü (Bidirectional) LSTM mimarisinin kullanılması tercih edilmiştir.

Bu bağlamda, çift yönlü LSTM mimarisi, metinlerdeki hem geçmiş hem de gelecek kelime bağlamlarını öğrenme kapasitesi sayesinde daha derin anlamsal ilişkileri modelleyebilmekte ve duygu sınıflandırma gibi görevlerde daha yüksek doğruluk sağlamaktadır. Özellikle uzun bağımlılıkları içeren metinlerde, klasik RNN ve tek yönlü LSTM mimarileri bu ilişkileri yeterince güçlü şekilde öğrenemezken, bidirectional LSTM sayesinde model, bir kelimenin hem önceki hem de sonraki kelimelerle olan bağımlı dikkate alarak daha anlamlı çıkarımlar yapabilmektedir. Bu durum, özellikle olumsuzluk belirten ifadelerin doğru sınıflandırılması gibi bağlama duyarlı durumlarda modelin başarımını artırmıştır.

Table 4: RNN Modelleri Performans Tablosu

Model	Model Accuracy	Test Accuracy	Precision	Recall	F1-Score
Tensorflow Tokenizer + SimpleRNN	0.8515	0.7997	0.803	0.800	0.798
Word2Vec + Bidirectional LSTM	0.8623	0.8449	0.849	0.845	0.845
GloVe + Bidirectional LSTM	0.8095	0.7981	0.789	0.789	0.789
FastText + Bidirectional LSTM	0.8184	0.7989	0.799	0.799	0.799

En başarılı modellerin Word2Vec + Bidirectional LSTM ile oluşturulan model olduğu görülmektedir.

References

- [1] Batbaatar, E., Li, M., Ryu, K. H. (2019). Semantic-emotion neural network for emotion recognition from text. IEEE access, 7, 111866-111878.
- [2] Chen, L. S., Liu, C. H., Chiu, H. J. (2011). A neural network based approach for sentiment classification in the blogosphere. journal of informetrics, 5(2), 313-322.
- [3] Despotovic, V., Tanikic, D. (2017). Sentiment analysis of microblogs using multilayer feed-forward artificial neural networks. Computing and Informatics, 36(5), 1127-1142.
- [4] Kim, C. G., Hwang, Y. J., Kamyod, C. (2022). A study of profanity effect in sentiment analysis on natural language processing using ann. Journal of web engineering, 21(3), 751-766.
- [5] Kumar, A., Rani, R. (2016, October). Sentiment analysis using neural network. In 2016 2nd International Conference on Next Generation Computing Technologies (NGCT) (pp. 262-267). IEEE.
- [6] Hasan, M., Rundensteiner, E., Agu, E. (2019). Automatic emotion detection in text streams by analyzing twitter data. International Journal of Data Science and Analytics, 7(1), 35-51.
- [7] Binali, H., Wu, C., Potdar, V. (2010, April). Computational approaches for emotion detection in text. In 4th IEEE international conference on digital ecosystems and technologies (pp. 172-177). IEEE.
- [8] Tao, J. (2004, October). Context based emotion detection from text input. In Interspeech (pp. 1337-1340).
- [9] Acheampong, F. A., Wenyu, C., Nunoo-Mensah, H. (2020). Text-based emotion detection: Advances, challenges, and opportunities. Engineering Reports, 2(7), e12189.
- [10] Agrawal, A., An, A. (2012, December). Unsupervised emotion detection from text using semantic and syntactic relations. In 2012 IEEE/WIC/ACM international conferences on web intelligence and intelligent agent technology (Vol. 1, pp. 346-353). IEEE.
- [11] Z. Jianqiang, G. Xiaolin, and Z. Xuejun, "Deep Convolution Neural Networks for Twitter Sentiment Analysis," IEEE Access, vol. 6, pp. 23253–23260, 2018, doi: 10.1109/ACCESS.2017.2776930..
- [12] Arkhipenko K. et al., "Comparison of Neural Network Architectures for Sentiment Analysis of Russian Tweets", Dialogue 2016.
- [13] Wang X. et al., "Combination of CNN and RNN for Sentiment Analysis of Short Texts", arXiv:1508.06615, 2015.
- [14] Nistor S.C. et al., "Building a Twitter Sentiment Analysis System with RNNs", Sensors 21(7), 2266, 2021.

- [15] Cai G. & Xia B., "Convolutional Neural Networks for Multimedia Sentiment Analysis", LNCS 9362, 159-167, 2015.
- [16]Thakkar, A., Mungra, D., Agrawal, A., Chaudhari, K. (2022). Improving the performance of sentiment analysis using enhanced preprocessing technique and artificial neural network. IEEE transactions on affective computing, 13(4), 1771-1782.
- [17]Mikolov T. et al., "Efficient Estimation of Word Representations in Vector Space", arXiv:1301.3781, 2013
- [18]Glenn, Aaron, Phillip LaCasse, and Bruce Cox. "Emotion classification of Indonesian tweets using bidirectional LSTM." Neural Computing and Applications 35.13 (2023): 9567-9578.
- [19]Sunagar, Pramod, and Anita Kanavalli. "A hybrid RNN based deep learning approach for text classification." International Journal of Advanced Computer Science and Applications 13.6 (2022).
- [20]Srinivasarao, Ulligaddala, and Aakanksha Sharaff. "SMS sentiment classification using an evolutionary optimization based fuzzy recurrent neural network." Multimedia Tools and Applications 82.27 (2023): 42207-42238.